Tool Call Testing Policy - переносима форма

Система: [назва] Версія системи, моделі та інструментів: [версії] Власник suite: [роль] Дата й статус: [заповнити]

1. Система і межі

Призначення агента: [опис]. Дії та зовнішні системи в межах перевірки: [перелік]. Поза межами перевірки: [перелік].

2. Прогноз і результат

Зафіксуйте прогноз до першого запуску; після запуску додайте результат. Не змінюйте початковий прогноз заднім числом.

Метрика	Числовий прогноз	Підстава	Результат і розмір вибірки
Частота хибної дії	[значення]	[підстава]	[результат]
Вартість із кешем і без	[значення]	[підстава]	[результат]

Доказ часу фіксації прогнозу: [коміт або інший запис]. Технічні помилки та незавершені спроби: [окремий облік].

3. Текст, дія і тест одного кроку

Текст відповіді та виклик інструмента перевіряються окремо. Для тесту кроку N відтворіть попередні відповіді моделі моком на межі API. Реальні інструменти мають відновити потрібний стан; лише крок N іде в модель. Визначте спосіб вибору спана живого кроку й прив'язки до сесії. Збережіть сценарій, версії, payload, результат, трейс і стан до наступного reset. Перевірте, що підготовчі запити справді обслуговує мок.

4. Три вимірники виклику

Вимірник	Дефект і очікування	Де доказ	level	gate / runs
Інструмент	[потрібний і заборонений]	[спан]	[рівень]	[режим]
Параметри	[ідентифікатор, сума, одиниці]	[payload та еталон]	[рівень]	[режим]
Порядок	[передумова перед дією]	[зв'язані спани]	[рівень]	[режим]

Порядок задавайте патерном потрібних залежностей. Не вимагайте рівності повного списку дозволених викликів.

5. Стан і повтор

Для write додайте assertion на виклик і assertion на стан після нього. Очікуваний ефект: [таблиця або журнал, поля, кількість]. Повтор того самого наміру: [сценарій та очікувана кількість ефектів]. Прямий повтор інструмента: [окремий тест ідемпотентності]. Ключ ідемпотентності та поведінка після транспортного збою: [правило].

6. Write, якого не мало бути

Заборонена дія та причина заборони: [опис]. Очікування на виклик: [нуль викликів]. Очікування на стан: [нуль нових ефектів]. Додайте випадки відсутньої згоди, відмови й неоднозначного результату. Відмова має блокувати виконання до незворотного ефекту.

7. Таблиця ризику інструментів

Додайте окремий рядок для кожного інструмента системи.

Інструмент	Клас	Межа незворотності	Наслідок помилки
[назва]	[read / compute / write зворотний / write незворотний]	[момент]	[наслідок]

Для read також оцініть права доступу та розкриття даних. Видалення локального запису не обов'язково скасовує зовнішній ефект.

8. Блокуючі перевірки і gate

Незворотний інструмент	Форма перевірки до виконання	Ціна або затримка	Законний сценарій, якому заважає
[назва]	[локальна / доменний рушій / оператор]	[значення та джерело]	[приклад]

Кожен сценарій має gate і runs. Daily: один прогін, детермінований вердикт; виклик може бути передумовою. Release: повторні прогони вибору, порядку, відмови та кешу. Конкретна кількість повторів і критерій проходження: [значення та причина]. Обробка assertion FAIL і технічного ERROR в CI: [правило].

9. Специфікація і контракт результату

Версіонуйте опис, input schema, output contract та доменні правила. Власник зміни й порядок погодження: [ролі та процедура]. Обов'язкові поля, типи й поведінка при невідомому результаті: [контракт]. Контракт результату перевіряйте окремим детермінованим сценарієм. Анотації інструмента є заявами, які suite має підтвердити.

10. Кеш і вартість

Стабільний префікс: [що входить]. Зміни, які руйнують кеш: [префікс інструкцій], [опис або порядок інструментів], [змінні дані перед стабільною частиною]. Поріг cache_read_min і початковий виклик перевірки: [значення]. Модель, дата й джерело тарифів: [посилання].

Умова	Прогони	Input / cached / output	Ціна кроку
З кешем	[кількість]	[usage]	[значення]
Без кешу	[кількість]	[usage]	[значення]

Позначте, чи це рахунок провайдера, чи розрахункова оцінка. Для оцінки відніміть cached tokens із input перед застосуванням тарифів. Різна довжина output заважає приписати всю різницю ціни лише кешу. Невідома ціна не дорівнює нулю.

11. Межі готової метрики

Що метрика перевіряє: [перелік]. Що потрібно додати: [збір спанів, стан, контракт, повтор, кеш]. Як налаштовано параметри та порядок: [опис]. Непокриті питання: чи була дія потрібна, чи правильні слова користувача, чи відповідає тестовий стан production.

12. Залишковий ризик

Не покрито	Наслідок	Чому приймаємо зараз	Відкласти чи прийняти; власник і умова перегляду
[прогалина]	[вплив]	[обґрунтування]	[рішення]

Підсумковий статус готовності та докази: [заповнити].