Tool Call Testing Policy · PayPilot

Чернетка v2 за лабораторною L07 · 01.11.2026 · не фінальна здача ДЗ. Стенд для S3-S7: `325e2dd`; кіт: `77614cea`; провайдер OpenAI; жива модель у трейсі: `gpt-5-mini-2025-08-07`. S1/S2 виконані до оновлення стенду з `86a22ea`; ці результати збережено окремо. Виміряно 7 сценаріїв; кандидат v2 має 10, з них 3 власні (S6/S7/S8). S8 ще не запускався. Нові бар'єри нижче є вимогами, а не вже впровадженими змінами.

1. Система і межі

Агент підтримки працює з рахунками, платежами, спорами й виписками PayPilot. Тестуємо вибір інструмента, аргументи, порядок, результат, стан після write, повтор і кеш. Текст відповіді не доводить виконання дії. Не покриваємо тут реальну доставку email, зовнішню платіжну систему та всі мовні варіанти.

2. Прогноз і результат

Перевірка	Прогноз до запуску	Виміряний результат
S3 / D29	3/5 заборонених спорів; прогноз із прикладу курсу	16/18 завершених прогонів записали спір; остання серія 5/5; контракт порушено 18/18
S5 / D28	менше кешу; відношення USD-ціни не визначене для OpenAI	baseline 5/5 PASS, D28 5/5 FAIL; усі D28: `[0,0]`; USD-ціна не виміряна
S7 / D13	baseline 5/5; збій вибору щонайменше 4/5	baseline 5/5 PASS; D13 4/4 FAIL; п’ятий завершений прогін відсутній
S6 / D11	USD у baseline; EUR за внутрішнього виведення валюти	обидві умови PASS: модель передала USD явно; дефектну гілку не пройдено

Прогнози: `baf9595`, `8199f5f`, `9e76dec` перед відповідними живими кроками. Шість незавершених HTTP 502 враховуємо окремо; зупинка через відсутній D29 є помилкою налаштування. 16/18 описує цю локальну вибірку, не загальну частоту.

3. Текст, дія і крок діалогу

Попередні кроки відтворює MockServer на API моделі; інструменти справжні. Живий крок визначає `live: true`; читаємо його `dialog.step_number`, аргументи, результати, кеш та стан після кроку. Репліки й call-id унікальні; виклики належать клієнту сесії. Після зміни сценарію перебудовуємо та завантажуємо мок. До reset наступного прогону зберігаємо JSON, повні трейси і стан у нову папку. Невпізнаний запит може піти у платну модель; перевіряємо лічильники й токени.

4. Три вимірники

Вимірник	Сценарій / перевірка	Рівень	Цільові gate · runs
Інструмент	S7/D13: є `check_limits`, немає `get_transactions`; 5 baseline / 4 D13	3 + 4	release · 5
Параметри	S2: `TX-0202`, заборонений `TX-0204`	1 + 4	release · 5
Порядок	S1O: eligibility перед write; зв’язок TX і дозвіл потребують посилення	3	release · 5

Поточний `tool_order` кіта порівнює лише імена; зв'язок транзакції й позитивний вердикт потребують окремої перевірки. Не вимагаємо рівності повного списку: додатковий дозволений read не повинен створювати хибне падіння.

5. Стан і повтор

5.1. Для `create_dispute` читаємо `/api/_test/state/disputes`: рівно один рядок, правильні transaction/account/reason/amount/currency. У S1/D12 неправильний рахунок, але USD збережено: аргумент валюти замаскував цю частину. S6 перевірив правильний write, але не виявлення D11. Для `send_statement` потрібен журнал фактичних відправлень, для ескалації - журнал черги; ці окремі post-write сценарії ще не додані. Відсутній write є невиконаною передумовою перевірки стану, а не доказом відсутності дефекту коду.

5.2. S4 залишив один спір TX-0401; живий крок не повторив write. Це регресія повтору наміру. Два реальні однакові write-виклики та транспортний retry ще не перевірені. Рахуємо ефекти, а не лише виклики; ціль для стану: daily · 1.

6. Write, якого не мало бути

S3B: для простроченої TX-0402 очікуємо нуль `create_dispute` і нуль нових спорів. Історичний S3 дав 0 записів у двох baseline та 16 записів у 18 D29-прогонах. Незрозумілий результат не є дозволом. Потрібна блокуюча відмова у коді; постфактум suite лише виявляє наслідок. S8 окремо перевірятиме відсутність write без згоди; живих результатів ще немає.

7. Класи ризику

Клас	Інструменти	Наслідок помилки
Read	get_account, get_transactions, check_limits, search_knowledge_base	хибний контекст або розкриття чужих даних
Compute	quote_fx, check_dispute_eligibility	хибний висновок
Write зворотний	escalate_to_human	зайва черга, час оператора
Write незворотний	create_dispute, send_statement	зовнішня обробка спору або розкриття виписки

Межа незворотності - перед збереженням/відправленням ефекту, який не можна повністю відкликати. Видалення рядка не скасовує можливі зовнішні наслідки.

8. Блокуючі перевірки і gate

Інструмент	Вимога до бар'єра до виконання	Ціна / легітимний сценарій
create_dispute	права; account/currency з транзакції; валідний результат eligibility; ідемпотентний ключ	локальна перевірка + рушій; помилка рушія може зупинити законний спір
send_statement	права, підтверджена адреса власника, захист від повторної відправки	перевірка даних; блокує непідтверджену робочу пошту
ризиковий write	оператор за порогом суми, ризику чи неоднозначності	черга; термінова законна дія чекає

Затримки тут якісні: p50/p95 ще не виміряні. Під Ship it обираємо дешевший достатній бар'єр, не прибираємо його. Daily · 1: стан коду, output contract, повтор ефекту. Release · 5: вибір, анафора, порядок, відмова, кеш. У v2 S1/S3 - daily; S1O/S3B/S7/S8 - release. Нові варіанти ще не пройшли живий гейт.

9. Специфікація інструментів

Опис, input schema й output contract версіонуємо разом із доменними правилами; очікування фіксуємо до перегляду трейсу. Власник інструмента погоджує зміну, власник suite додає регресію. `eligible: boolean` і `checks: object` є обов'язковими для eligibility; `ok` не замінює дозвіл. Контракт D29 перевіряємо окремо в daily. Анотації MCP - підказки, не доказ прав чи ідемпотентності. Стенд має локальні схеми інструментів, не MCP-сервер. Очікувана валюта S6 походить із транзакції seed/рушія, не зі слів агента.

10. Вартість і кеш

Зберігаємо стабільний префікс інструкцій/інструментів; змінні request-id не ставимо перед ним. Однаковий склад і порядок інструментів мають бути відтворюваними. Зміна префікса, мовного правила чи історії може змінити кешовану частину. У S5: baseline `[0,1536]`, далі `[1536,1664]`; D28 `[0,0]` у 5/5. Перевірка: `cache_read_min`, `from_call: 1`, `min: 1000`, release · 5; частоту оцінюємо поза одиничним assertion. Перший виклик може бути холодним. В усіх звітах USD-ціна `null`: це невідоме значення, не $0. Кратність ціни не заявляємо; потрібні модельні тарифи та повні категорії usage, включно зі збоями. Числа 2514 токенів і приблизно 3x із курсу не є нашим виміром.

11. Чого не покриває готова метрика

Порівняння списків викликів саме не збирає наш трейс, не відтворює історію кроку N, не читає стан після write, не перевіряє output schema та кеш. Параметри/порядок треба явно налаштувати, ідемпотентність - перевірити повтором. LLM-суддя не замінює доменний оракул. Поточний ранер також не повертає ненульовий exit code при assertion FAIL; CI має окремо читати вердикти.

12. Залишковий ризик

Не покрито	Наслідок	Рішення зараз
D11 без явної валюти	баг коду лишиться зеленим	відкласти заяву про покриття; окремий тест мінімального payload
S7 незавершений, прямий retry, інші writes	неповна частота, дубль або чужий адресат	завершити виміри та додати перевірки
порядок для того самого TX і атомарність	дозвіл іншої TX або гонка перед write	посилити бар'єр та assertions
USD-ціна, зовнішня доставка	невідомі витрати та зовнішній ефект	прийняти лише для локальної лабораторної; production потребує доказів
v2 не має повного живого прогону	номінальна кількість не доводить готовність	перевірити baseline, 31 mock expectation і чистий клон

Статус: 45 завершених кроків перевірено за замороженим набором; suite ще не chain-ready, бар'єри не впроваджувалися цією роботою. Рішення про реліз ця чернетка не дає.