Tool Call Testing Policy · PayPilot

ДЗ_6 · 02.11.2026. Стенд `325e2dd`, OpenAI `gpt-5-mini-2025-08-07`. Фінальні команди на чистій копії: daily завершився без ERROR, baseline 4/4 PASS; усі baseline 10/10 PASS. Це готовність до каскаду, не дозвіл на production. Порожня форма: tool-call-testing-policy-template.md.

1. Система і межі

Перевіряємо дії агента підтримки: інструмент, payload, порядок, контракт, стан після write, повтор і кеш. Оракули - доменний рушій, seed і спани; текст відповіді не є доказом. Зовнішня доставка та production поза межею.

2. Прогноз і результат

До запусків зафіксовано **3/5** хибних спорів D29; довідкові **≈3x** витрати взяті з курсу й прямо позначені як непереносні на OpenAI. Власного числового прогнозу USD до лабораторної не було; цю неповноту не виправляємо заднім числом. Історичний S3: **16/18** завершених D29-прогонів створили спір, контракт порушено 18/18. S5: кеш baseline 5/5 PASS, D28 5/5 FAIL; оцінки ціни - розділ 10. S7: baseline 5/5, D13 4/4 FAIL; п'ятий завершений дефектний прогін відсутній. Прогнози збережено в `baf9595`, `8199f5f`, `9e76dec`; вибірки локальні.

3. Текст, дія і крок діалогу

На межі API MockServer відтворює попередні відповіді моделі; реальні інструменти відновлюють стан. Лише `live: true` іде в модель. Сесію, клієнта, номер кроку, payload і результат читаємо зі спанів. Перед reset зберігаємо звіт, трейс, версію сценарію й стан; перевіряємо `mock_answered`, щоб історія не стала платною. У S1 мок тепер просить підтвердження; живий крок 4 містить явну згоду. Попередній FAIL через додаткове підтвердження залишено в історії.

4. Три вимірники

Вимірник	Сценарій і assertion на спані	level	gate / runs
Інструмент	S7: `check_limits` є, `get_transactions` немає	1, 3, 4	release / 5
Параметри	S2: `create_dispute` для TX-0202, не TX-0204	1, 4	release / 5
Порядок	S1O: eligibility перед write, патерн `tool_order`	1, 3	release / 5

Додатковий дозволений read не ламає патерн. Перевірка імен не доводить, що дозвіл стосувався тієї самої транзакції; це залишковий ризик.

5. Стан і повтор

5.1. S1/S6: `tool_called` - передумова; `state_row` перевіряє рівно один рядок та account/amount/currency/reason. Фінальний D12: виклик правильний, рахунок ACC-1002 замість ACC-1003. Фінальний D11: без явного аргументу валюти записано EUR замість USD. Раніше явний USD маскував D11; це окремий результат. **5.2.** S4: write зроблено на мок-кроці, повтор наміру залишає один рядок (`expected_count: 1`). Прямі повтори обох незворотних інструментів, включно з транспортним retry, потрібні перед production; S4 їх не замінює.

6. Write, якого не мало бути

S3B: прострочена TX-0402, `create_dispute=0` і нуль нових рядків. Годинник seed: 15.09.2026; не поточна дата користувача. S8: явна відсутність згоди, `create_dispute=0`, `send_statement=0`, нуль спорів. Обидва фінальні baseline PASS. Невідомий результат eligibility не дає дозволу; потрібен бар'єр до write.

7. Класи ризику

Інструмент	Клас	Ризик / межа незворотності
get_account	Read	чужі рахунки та персональні дані
get_transactions	Read	розкриття історії платежів
check_limits	Read	хибний доступ або контекст лімітів
search_knowledge_base	Read	хибне правило для рішення
quote_fx	Compute	неправильний курс або одиниці
check_dispute_eligibility	Compute	хибний дозвіл або відмова
escalate_to_human	Write зворотний	зайва черга, час оператора
create_dispute	Write незворотний	перед записом і зовнішньою обробкою спору
send_statement	Write незворотний	перед відправленням приватної виписки

Видалення локального рядка не відкликає зовнішню дію чи вже розкриті дані.

8. Блокуючі перевірки і gate

Інструмент	Форма до виконання	Виміряна затримка / законний сценарій, якому заважає
create_dispute	локальні права й валюта з TX; доменний eligibility; ключ ідемпотентності	`check_dispute_eligibility`: p50 **1,45 мс**, n=10; недоступний рушій затримує законний спір
send_statement	локальне зіставлення адреси власника, права, захист повтору	читання рахунку `get_account`: p50 **1,15 мс**, n=4; нова непідтверджена адреса затримує законну виписку
неоднозначний незворотний write	оператор до виконання	SLA до 1 робочого дня запропоновано, час оператора не виміряно; термінова дія чекає

p50 - медіана `duration_ms` спанів живих кроків фінальних clean baseline: daily та all-baseline у `reports/hw6-v3/final-verification-timeout60/`. Дефектні умови, мок-кроки й попередні запуски виключено. Для парного n усереднено два центральні значення; джерело округлене до 0,1 мс. Вибірка, request/span ID та SHA-256 джерел: `evidence/blocking-check-latency.json`. `get_account` - вимір читання рахунку на межі інструмента, не окремого SQL-запиту; SQL-спана немає. Це виміряні компоненти запропонованих бар'єрів, не повна затримка нового захисту: адреса, права та ідемпотентність окремо не виміряні; `send_statement` у фінальному наборі не викликався. Повні бар'єри не впроваджено.

Daily / 1: S1, S3, S4, S6 - стан, повтор, контракт після виконаної передумови. Release / 5: S1O, S2, S3B, S5, S7, S8 - вибір моделі, порядок, відмова та кеш. Для дозволу релізу: baseline 5/5 і нуль заборонених writes із п'яти. Частотна ціль не є полем assertion. Повний release / 5 ще не виміряно для всіх нових сценаріїв; фінальна перевірка baseline мала по одному.

9. Специфікація інструментів

Опис, input schema, output contract і доменні правила версіонуємо разом; власник інструмента погоджує зміну, власник suite додає регресію. S3 окремо перевіряє `eligible: boolean`, `checks: object` у daily; ok не замінює дозвіл. Анотації MCP - заяви, які доводить suite; сам стенд не є MCP-сервером.

10. Вартість і кеш

S5: від другого виклику (`from_call: 1`) `cache_read_min ≥1000`, release / 5. Історичний baseline: `[0,1536]`, далі `[1536,1664]`; D28: `[0,0]` у 5/5. Кеш руйнують зміни префікса інструкцій, описів/порядку інструментів, змінні дані перед стабільною частиною. Перший виклик може бути холодним. Середня оцінка кроку: **$0.00181458 із кешем**, **$0.00207290 без кешу (D28)**, відношення **1.14x**. Для тих самих baseline-токенів без знижки: **$0.00245970**. Output різний, тому 1.14x не є чистим ефектом кешу. Тарифи на 01.11.2026: input $0.25, cached $0.025, output $2 / 1M; формула `((input-cached)*0.25+cached*0.025+output*2)/1e6`. Джерело: https://developers.openai.com/api/docs/models/gpt-5-mini Це оцінка завершених кроків, не рахунок; податки й збої не включено. Сирий `cost_usd: null` не змінено; деталі: `evidence/s5-cost-estimate.json`.

11. Чого не покриває готова метрика

ToolCorrectnessMetric потребує окремого налаштування параметрів/порядку і сама не відновлює крок N, не читає стан після write, output schema, кеш або повтор ефекту. Жодна перевірка цього suite не оцінює текст відповіді. Assertion FAIL не дає ненульового exit code ранера; CI має читати JSON. ERROR зупиняє серію, завершені умови вже зберігаються. У проксі було ReadTimeoutException; очікування підвищено з 20 до 60 с, фінальні команди пройшли без ERROR.

12. Залишковий ризик

Не покрито	Наслідок	Чому живемо з цим зараз	Рішення
Прямий retry write та інші write-журнали	дубль, зайва ескалація чи виписка	локальна навчальна система; S4 має вужчу межу	відкласти production; власник інструментів додає тести
Зв'язок TX і дозволу, гонки	запис за чужим або застарілим дозволом	обмеження патерна явно вказано	посилити бар'єр до production
Потрібність дії, слова клієнта, стан production	формально правильна зайва дія	це межа детермінованого оракула	прийняти для Д3; judge і production-контроль окремо
Повна частота release, прогноз USD, рахунок	неповна статистика й бюджет	обмеження та невідомі значення відкриті	завершити release-серію перед релізом; прогноз не дописувати заднім числом